

TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP
KHOA ĐIỆN TỬ

Bộ môn : Công Nghệ Thông Tin



BÀI TIỂU LUẬN

MÔN HỌC

KHOA HỌC DỮ LIỆU

PHÂN TÍCH VÀ DỰ BÁO THỜI TIẾT Ở VIỆT NAM

HỌ VÀ TÊN	:	NGUYỄN TUẤN ANH
LỚP	:	K58KTP.01
MSSV	:	K225480106095
GVHD	:	TS. NGUYỄN VĂN HUY

Thái Nguyên 2026

BÀI TIỂU LUẬN
MÔN: KHOA HỌC DỮ LIỆU

Sinh viên : Nguyễn Tuấn Anh MSSV: K225480106095 Lớp: K58KTP

Ngành học: Kỹ thuật máy tính

Giáo viên hướng dẫn: TS. Nguyễn Văn Huy

Đề tài: Phân tích và dự đoán thời tiết ở Việt Nam

1. Nội dung báo cáo:

- *Thống kê và phân tích thời tiết ở Việt Nam*
- *Dự đoán và phân cụm các tỉnh thành theo lượng mưa*

2. Sản phẩm:

- *Slide thuyết trình*
- *File báo cáo bài tiểu luận*
- *Code ipynb*

3. Ngày giao nhiệm vụ: ngày 01 tháng 06 năm 2026

Ngày hoàn thành nhiệm vụ: ngày 20 tháng 06 năm 2026

Thái Nguyên, Ngày... Tháng... Năm 2026

GIÁO VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

NHẬN XÉT CỦA GIÁO VIÊN

.....

.....

.....

.....

.....

.....

Thái Nguyên, Ngày... Tháng... Năm 2026

GIÁO VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

MỤC LỤC

CHƯƠNG I: GIỚI THIỆU	7
1.1. Lý do chọn đề tài	7
1.2. Mục tiêu và phạm vi nghiên cứu	8
1.2.1. Mục tiêu nghiên cứu	8
1.2.2. Phạm vi nghiên cứu	9
1.3. Quy trình thực hiện	10
1.4. Tổng quan về các công cụ và môi trường phát triển	11
CHƯƠNG II: QUY TRÌNH THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU	13
2.1 Giới thiệu bộ dữ liệu	13
2.2. Ý nghĩa các thuộc tính	14
2.3 Khảo sát dữ liệu ban đầu	15
2.4. Quy trình làm sạch dữ liệu (Data Cleaning)	17
2.4.1. Khảo sát và xử lý giá trị khuyết thiếu (Missing Values)	17
2.5. Phân tích và xử lý đặc trưng	18
2.5.1. Trích xuất thuộc tính chu kỳ thời gian (Temporal Features)	18
2.5.2. Mã hóa biến phân loại (Categorical Encoding)	19
2.5.3. Chuẩn hóa thang đo dữ liệu (Feature Scaling)	19
2.6. Mã hóa đặc trưng	20
2.7. Chuẩn hóa dữ liệu	21
CHƯƠNG III: PHÂN TÍCH THỐNG KÊ	22
3.1. Top 5 tỉnh thành có nhiệt độ trung bình cao nhất trong năm 2021	22
3.1.1. Mục tiêu phân tích	22
3.1.2. Phương pháp thực hiện	22
3.2. Tỉnh thành có lượng mưa cao nhất trong năm 2021	23
3.2.1. Mục tiêu phân tích	23
3.2.2. Phương pháp thực hiện	23
3.3. Thống kê lượng mưa theo tháng của tỉnh có lượng mưa cao nhất trong năm 2021	24
3.3.1. Mục tiêu phân tích	24
3.3.2. Phương pháp thực hiện	24
3.4. Tỉnh thành có lượng mưa nhỏ nhất toàn diện	25
3.4.1. Mục tiêu phân tích	25
3.4.2. Phương pháp thực hiện	25

3.5. Tỉnh thành có số ngày mưa liên tục nhiều nhất trong năm 2021	26
3.5.1. Mục tiêu phân tích	26
3.5.2. Phương pháp thực hiện	26
3.6. Đánh giá kết quả	27
CHƯƠNG IV: XÂY DỰNG MÔ HÌNH HỌC MÁY PHÂN CỤM VÀ DỰ ĐOÁN	29
4.1. Dự đoán lượng mưa của tỉnh thành có lượng mưa cao nhất trong vòng 1 tháng tới	29
4.1.1. Mục tiêu phân tích và Ý nghĩa thực tiễn	29
4.1.2. Phương pháp thực hiện và Mô hình lựa chọn	29
4.2. Phân cụm các tỉnh thành theo nhóm có lượng mưa cao	30
4.2.1. Mục tiêu phân tích và Ý nghĩa thực tiễn	30
4.2.2. Phương pháp thực hiện và Mô hình lựa chọn	30
4.3. Đánh giá kết quả chương IV	31
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	32
5.1. Kết luận	32
TÀI LIỆU THAM KHẢO	34

DANH MỤC BẢNG VÀ HÌNH ẢNH

Hình 2.1. Nguồn DataSet sử dụng cho bài toán

Bảng 2.2. Đặc tả ý nghĩa các thuộc tính trong bộ dữ liệu gốc

Hình 2.3.1. Dữ liệu 5 dòng đầu tiên

Hình 2.3.2. Thông tin các cột dữ liệu

Hình 2.4.1: Thống kê giá trị khuyết thiếu

Hình 2.5.1. Cấu trúc tập dữ liệu sau khi xử lý thuộc tính thời gian

Hình 2.5.1. Dữ liệu sau khi chuẩn hóa

Hình 2.6: Kết quả dữ liệu đã chuẩn hóa mã hóa

Hình 2.7: Thống kê mô tả ma trận đặc trưng sau chuẩn hóa Z-SCORE

Hình 3.1: Top 5 tỉnh thành có nhiệt độ trung bình cao nhất năm 2021

Hình 3.2: Tỉnh thành có lượng mưa trung bình cao nhất năm 2021

Hình 3.3: Thống kê lượng mưa theo tháng của tỉnh có lượng mưa cao nhất trong năm 2021

Hình 3.4. Tỉnh thành có lượng mưa nhỏ nhất toàn diện

Hình 3.5. Tỉnh thành có số ngày mưa liên tục nhiều nhất trong năm 2021

Hình 4.1: Biểu đồ so sánh Lượng mưa Thực tế và Dự báo trong 1 tháng tới tại Hòa Bình

Hình 4.2: Biểu đồ phân cụm K-Means các tỉnh thành theo Lượng mưa và Độ ẩm trung bình

LỜI MỞ ĐẦU

Thời tiết và khí hậu là những yếu tố tự nhiên có ảnh hưởng trực tiếp và sâu sắc đến mọi mặt của đời sống kinh tế - xã hội, từ hoạt động sản xuất nông nghiệp, giao thông vận tải, cho đến đời sống sinh hoạt hằng ngày của người dân. Việt Nam, với đặc điểm địa hình trải dài và khí hậu nhiệt đới gió mùa phức tạp, thường xuyên phải đối mặt với các diễn biến thời tiết thất thường và mang tính phân hóa mạnh mẽ giữa các vùng miền. Việc dự báo chính xác các chỉ số thời tiết cốt lõi như nhiệt độ và lượng mưa đóng vai trò chiến lược trong việc chủ động lên kế hoạch và giảm thiểu rủi ro.

Trong những năm gần đây, sự bùng nổ của Khoa học dữ liệu (Data Science) và Học máy (Machine Learning) đã mở ra một phương tiếp cận mới dựa trên dữ liệu (Data-driven). Bằng cách khai thác kho dữ liệu lịch sử từ các trạm quan trắc, các mô hình học máy có khả năng tự động tìm ra các quy luật, mối tương quan ẩn và xu hướng biến động phức tạp của thời tiết theo thời gian mà các phương pháp thống kê truyền thống khó lòng bao quát hết.

Nhận thức được tầm quan trọng đó, em/nhóm em đã lựa chọn đề tài "Ứng dụng Khoa học dữ liệu và Học máy để phân tích, dự báo các chỉ số thời tiết tại Việt Nam" làm đồ án môn học. Nghiên cứu tập trung toàn diện vào quy trình chuẩn của một dự án Khoa học dữ liệu: từ thu thập, tiền xử lý dữ liệu khuyết thiếu, phân tích khám phá dữ liệu (EDA) để tìm ra quy luật khí hậu đặc trưng, cho đến thử nghiệm kỹ nghệ đặc trưng (Feature Engineering) và xây dựng các mô hình dự báo chuỗi thời gian (Time Series Forecasting). Qua đó, đồ án không chỉ củng cố kỹ năng xử lý dữ liệu thực tế mà còn hướng tới việc đưa ra một giải pháp tiếp cận công nghệ hiệu quả cho bài toán khí hậu.

CHƯƠNG I: GIỚI THIỆU

1.1. Lý do chọn đề tài

- Thời tiết và khí hậu là những yếu tố nền tảng có tác động trực tiếp, sâu sắc đến mọi hoạt động kinh tế – xã hội của một quốc gia. Đối với một nước có thế mạnh về nông nghiệp và đang trên đà phát triển đô thị hóa mạnh mẽ như Việt Nam, biến động của thời tiết lại càng mang tính quyết định. Do đặc thù địa hình trải dài trên nhiều vĩ độ và địa hình phức tạp, khí hậu Việt Nam có sự phân hóa rõ rệt giữa ba miền và thường xuyên phải chịu ảnh hưởng của các hiện tượng cực đoan. Sự thay đổi đột ngột của nhiệt độ hay các đợt mưa lớn bất thường không chỉ gây thiệt hại cho sản xuất, làm gián đoạn chuỗi cung ứng, giao thông vận tải mà còn đe dọa trực tiếp đến đời sống và sức khỏe của người dân. Chính vì vậy, việc xây dựng một hệ thống phân tích và dự báo chính xác các chỉ số thời tiết cốt lõi (nhiệt độ, lượng mưa) là một nhu cầu cấp bách mang ý nghĩa thực tiễn cao.

- Trước đây, việc dự báo thời tiết chủ yếu dựa trên các mô hình vật lý lý thuyết và mô hình số hóa khí tượng thủy văn truyền thống. Mặc dù các phương pháp này có độ chính xác nhất định, nhưng chúng đòi hỏi hệ thống siêu máy tính cực kỳ phức tạp và gặp nhiều thách thức trước những biến đổi phi tuyến tính, bất thường do biến đổi khí hậu toàn cầu gây ra.

- Sự phát triển mạnh mẽ của Khoa học dữ liệu (Data Science) và Học máy (Machine Learning) đã mở ra một hướng đi mới: tiếp cận dựa trên dữ liệu thực tế (Data-driven approach). Dữ liệu thời tiết lịch sử được ghi nhận liên tục qua các ngày, các năm thực chất là một kho tàng thông tin ẩn chứa các quy luật, tính chu kỳ và xu hướng theo thời gian. Bằng cách áp dụng các thuật toán học máy, chúng ta có thể khai phá các mối tương quan phức tạp giữa các chỉ số khí tượng (như mối quan hệ giữa độ ẩm, áp suất ảnh hưởng đến lượng mưa và nhiệt độ) mà không cần phụ thuộc hoàn toàn vào các phương trình vật lý phức tạp. Việc ứng dụng các mô hình dự báo chuỗi thời gian (Time Series) hay các thuật toán phân loại trong Học máy giúp tối ưu hóa thời gian xử lý, tăng cường khả năng thích ứng với dữ liệu mới và đưa ra các dự báo có độ tin cậy cao.

- Là những sinh viên ngành công nghệ, việc đối mặt và giải quyết một bài toán có cấu trúc dữ liệu thực tế, liên tục và có độ nhiễu cao như dữ liệu thời tiết là một cơ hội lớn để

rèn luyện tư duy. Đề tài này được lựa chọn nhằm mục đích áp dụng toàn diện quy trình chuẩn của một dự án Khoa học dữ liệu, bao gồm:

- Khai thác và làm sạch dữ liệu thô (xử lý dữ liệu khuyết thiếu, nhiễu hệ thống).
- Thực hiện phân tích khám phá (EDA) để trực quan hóa sự phân hóa khí hậu giữa các vùng miền tại Việt Nam.
- Áp dụng các kỹ thuật kỹ nghệ đặc trưng (Feature Engineering) trên dữ liệu chuỗi thời gian.
- Xây dựng, thử nghiệm và đánh giá hiệu năng của các mô hình Học máy để tìm ra phương án tối ưu nhất.
- Xuất phát từ những lý do mang tính thực tiễn, tính khoa học và mục tiêu học tập nêu trên, em/nhóm em đã quyết định lựa chọn đề tài: “Ứng dụng Khoa học dữ liệu và Học máy để phân tích, dự báo các chỉ số thời tiết tại Việt Nam” làm đề án nghiên cứu cho môn học này.

1.2. Mục tiêu và phạm vi nghiên cứu

1.2.1. Mục tiêu nghiên cứu

- Mục tiêu tổng quát: Mục tiêu tổng quát của đề tài là ứng dụng quy trình khoa học dữ liệu diện rộng và các thuật toán học máy để khai phá kho dữ liệu thời tiết lịch sử tại Việt Nam. Thông qua đó, nghiên cứu hướng đến việc chuyển hóa các dữ liệu khí tượng dạng thô thành các tri thức hữu ích, trực quan hóa được bức tranh toàn cảnh về khí hậu, và xây dựng thành công mô hình học máy có khả năng dự báo chính xác xu hướng biến động của các chỉ số thời tiết cốt lõi trong tương lai.

- Các mục tiêu cụ thể bao gồm:

+ Đề tài tập trung vào mục tiêu thu thập và xây dựng một kho dữ liệu sạch từ các nguồn quan trắc thời tiết lịch sử theo ngày tại Việt Nam. Quá trình này đòi hỏi phải thực hiện các kỹ thuật tiền xử lý dữ liệu chuyên sâu bao gồm việc phát hiện và loại bỏ các giá trị ngoại lai do lỗi thiết bị, chuẩn hóa định dạng các cột thuộc tính, và áp dụng các phương pháp nội suy toán học phù hợp như nội suy tuyến tính hoặc điền giá trị theo nhóm tháng để xử lý triệt để các khoảng dữ liệu bị khuyết thiếu, nhằm đảm bảo tính liên tục của chuỗi thời gian.

+ Nghiên cứu hướng tới mục tiêu phân tích khám phá dữ liệu bằng các công cụ trực quan hóa hiện đại để bóc tách và làm rõ các quy luật khí hậu. Cụ thể, nghiên cứu sẽ phân tích xu hướng thay đổi dài hạn của nhiệt độ qua các năm dưới tác động của biến đổi khí hậu, xác định tính chu kỳ theo mùa của lượng mưa, và sử dụng các ma trận tương quan để giải mã mối quan hệ ràng buộc giữa các chỉ số như áp suất, độ ẩm ảnh hưởng đến khả năng gây mưa. Đồng thời, bước phân tích này cũng nhằm định lượng hóa và so sánh sự phân hóa khí hậu rõ rệt giữa các trạm quan trắc đại diện cho ba miền Bắc, Trung, Nam.

+ Một mục tiêu kỹ thuật then chốt khác là thực hiện kỹ nghệ đặc trưng chuyên biệt cho dữ liệu chuỗi thời gian để tối ưu hóa cấu trúc đầu vào cho mô hình học máy. Nghiên cứu sẽ tiến hành trích xuất các thành phần thời gian từ cột ngày tháng thành các biến độc lập, xây dựng các biến trễ nhằm giúp mô hình tận dụng thông tin thời tiết của các ngày trước đó, và tạo ra các biến thống kê dựa trên cửa sổ cuộn như nhiệt độ trung bình của một tuần trước đó nhằm cung cấp cho mô hình cái nhìn toàn diện về bối cảnh thời tiết.

+ Đề tài đặt mục tiêu thử nghiệm, cấu hình và huấn luyện một tập hợp các thuật toán học máy đa dạng, đi từ các mô hình tuyến tính cơ bản cho đến các mô hình học máy nâng cao dựa trên cấu trúc cây quyết định và tăng cường độ dốc. Trên cơ sở đó, nghiên cứu sẽ tiến hành thực hiện quá trình đánh giá chéo và so sánh hiệu năng của các mô hình một cách nghiêm ngặt thông qua các chỉ số đo lường tiêu chuẩn trong khoa học dữ liệu bao gồm sai số bình phương trung bình dạng căn, sai số tuyệt đối trung bình và hệ số xác định. Mục tiêu cuối cùng của giai đoạn này là lựa chọn và tinh chỉnh được một mô hình tối ưu nhất, có khả năng giảm thiểu tối đa sai số và đưa ra những dự báo có độ tin cậy cao cho các chỉ số nhiệt độ và lượng mưa trong thực tế.

1.2.2. Phạm vi nghiên cứu

- Về phạm vi nội dung, đề tài tập trung nghiên cứu hai chỉ số thời tiết cốt lõi và có tác động lớn nhất đến đời sống là nhiệt độ (bao gồm nhiệt độ trung bình, nhiệt độ cao nhất, nhiệt độ thấp nhất) và lượng mưa theo ngày. Các yếu tố khí tượng bổ trợ khác như độ ẩm, tốc độ gió hay áp suất khí quyển sẽ được sử dụng đóng vai trò là các thuộc tính đầu vào để hỗ trợ nâng cao độ chính xác cho mô hình dự báo chuỗi thời gian, chứ không phải mục tiêu dự báo chính.

- Về phạm vi không gian, do đặc thù khí hậu Việt Nam có sự phân hóa vùng miền vô cùng phức tạp, nghiên cứu sẽ giới hạn phạm vi dữ liệu tại các tỉnh thành đại diện tiêu biểu cho ba miền Bắc, Trung, Nam và các vùng khí hậu đặc trưng, thay vì ôm đồm toàn

bộ hệ thống trạm quan trắc trên cả nước nhằm đảm bảo tính tập trung và giảm thiểu nhiều cho mô hình.

- Về phạm vi thời gian, nghiên cứu sử dụng tập dữ liệu lịch sử được ghi nhận liên tục theo ngày trong giai đoạn từ mười đến mười lăm năm trở lại đây. Đây là khoảng thời gian đủ dài để các thuật toán học máy có thể học được các quy luật chu kỳ theo mùa, đồng thời phản ánh rõ nét những xu hướng biến đổi khí hậu thực tế đang diễn ra trong dòng chảy thời gian hiện đại.

1.3. Quy trình thực hiện

- Quy trình triển khai đề tài được thiết kế một cách hệ thống và chặt chẽ, tuân thủ theo các giai đoạn chuẩn của một chu trình Khoa học dữ liệu nhằm đảm bảo tính khoa học và tiến độ thực hiện:

- **Giai đoạn 1:** Giai đoạn khởi đầu của quy trình là xác định bài toán và thu thập dữ liệu khí tượng thô. Trong bước này, nghiên cứu tiến hành thu thập dữ liệu thời tiết lịch sử theo ngày thông qua các tệp dữ liệu có sẵn từ các nguồn mở uy tín hoặc khai thác trực tiếp từ các hệ thống API thời tiết quốc tế. Tập dữ liệu sau khi thu thập sẽ chứa đầy đủ các thông tin cốt lõi về mốc thời gian, tên trạm quan trắc hoặc tỉnh thành, cùng hệ thống các chỉ số khí tượng bao gồm nhiệt độ cực đại, nhiệt độ cực tiểu, lượng mưa, độ ẩm trung bình, tốc độ gió và áp suất khí quyển.
- **Giai đoạn 2:** Sau khi sở hữu tập dữ liệu thô, quy trình chuyển sang giai đoạn tiền xử lý dữ liệu, một bước đi có tính chất quyết định đến độ chính xác của các mô hình dự báo sau này. Do đặc thù dữ liệu thực tế thường chứa nhiều nhiễu và các khoảng trống do lỗi kỹ thuật của trạm quan trắc, nghiên cứu sẽ tập trung kiểm tra cấu trúc dữ liệu, đồng bộ hóa định dạng thời gian và phát hiện các giá trị ngoại lai bất thường. Tiếp theo, các kỹ thuật xử lý dữ liệu khuyết thiếu sẽ được áp dụng, trong đó lượng mưa thiếu hụt thường được quy đổi về giá trị bằng không, còn các giá trị nhiệt độ bị trống sẽ được xử lý bằng phương pháp nội suy toán học dựa trên bối cảnh thời gian liền kề để đảm bảo tính liên tục của chuỗi dữ liệu.
- **Giai đoạn 3:** Giai đoạn thứ ba trong quy trình là phân tích khám phá dữ liệu và kỹ nghệ đặc trưng. Đây là lúc nghiên cứu sử dụng các thư viện trực quan hóa dữ liệu chuyên dụng để vẽ các biểu đồ xu hướng, biểu đồ hộp và ma trận tương quan nhằm thấu hiểu sâu sắc các quy luật khí hậu tự nhiên. Song song với việc phân tích, quá trình kỹ nghệ đặc trưng sẽ được triển khai bằng cách tách nhỏ cột thời

gian thành các thành phần độc lập như tháng hoặc mùa, đồng thời tính toán và tạo thêm các thuộc tính mới như các biến trễ thời gian và biến thống kê cửa sổ cuộn, giúp mô hình học máy có thể nắm bắt được bối cảnh thời tiết của các ngày trước đó.

- **Giai đoạn 4:** Giai đoạn cuối cùng và cũng là trọng tâm kỹ thuật của đề tài là xây dựng, huấn luyện và đánh giá mô hình học máy. Tập dữ liệu sau khi làm sạch và tối ưu hóa thuộc tính sẽ được phân chia thành các tập huấn luyện và tập kiểm thử theo một tỷ lệ thời gian phù hợp để tránh hiện tượng rò rỉ dữ liệu. Nghiên cứu sẽ tiến hành cấu hình và huấn luyện đồng thời nhiều thuật toán học máy khác nhau từ cấp độ cơ bản đến các thuật toán mạnh mẽ dựa trên cấu trúc cây quyết định. Hiệu năng của từng mô hình sẽ được đo lường, kiểm thử nghiêm ngặt thông qua các chỉ số sai số tiêu chuẩn trong khoa học dữ liệu nhằm tìm ra mô hình xuất sắc nhất. Quy trình sẽ khép lại sau khi tinh chỉnh thành công các siêu tham số của mô hình tối ưu này, đảm bảo hệ thống đạt được sai số thấp nhất và có khả năng đưa ra những dự báo thời tiết đáng tin cậy.

1.4. Tổng quan về các công cụ và môi trường phát triển

- Dưới đây là phần Tổng quan về các công cụ và môi trường phát triển được thiết kế chuyên biệt cho một đề án Khoa học dữ liệu, tập trung vào hệ sinh thái Python và các công cụ quản lý mã nguồn, được viết liền mạch thành các đoạn văn hoàn chỉnh để đưa trực tiếp vào báo cáo của bạn:

- **Python:** Ngôn ngữ lập trình bậc cao, mã nguồn mở, sở hữu hệ sinh thái thư viện phong phú và mạnh mẽ nhất hiện nay trong lĩnh vực Khoa học dữ liệu nhờ cú pháp đơn giản, tối giản hóa mã nguồn.
- **Jupyter Notebook:** Ứng dụng web cho phép viết và thực thi các khối mã mã nguồn độc lập, hiển thị kết quả và biểu đồ trực quan ngay lập tức, phục vụ tối ưu cho việc thử nghiệm dữ liệu.
- **Môi trường ảo (Anaconda):** Công cụ quản lý và tạo không gian lưu trữ biệt lập cho dự án, giúp cài đặt các phiên bản thư viện riêng biệt, tránh xung đột hệ thống và dễ dàng đóng gói mã nguồn.
- **Pandas:** là thư viện chuyên dùng để xử lý và phân tích dữ liệu dạng bảng. Thư viện cung cấp cấu trúc dữ liệu DataFrame giúp thao tác, lọc, làm sạch và thống kê dữ liệu một cách thuận tiện.

- **NumPy**: là thư viện hỗ trợ tính toán số học và xử lý mảng đa chiều hiệu quả. Đây là nền tảng cho nhiều thư viện khoa học dữ liệu khác trong hệ sinh thái Python.
- **Matplotlib và Seaborn**:
 1. Matplotlib: Thư viện đồ họa nền tảng chịu trách nhiệm khởi tạo khung hình, cấu hình trục tọa độ, quản lý font chữ tiếng Việt hiển thị trên biểu đồ và xuất tệp tin hình ảnh chất lượng cao dạng đồ họa vector
 2. Seaborn: Thư viện trực quan hóa dữ liệu cao cấp được xây dựng phía trên Matplotlib. Seaborn cung cấp giao diện biểu đồ hiện đại, các bảng màu sắc chuyên nghiệp (viridis, coolwarm, magma), tự động tối ưu các đường phân phối thống kê, giúp việc biểu diễn biểu đồ EDA trở nên trực quan và mang tính thuyết phục học thuật cao.
- **Scikit-learn**: Thư viện học máy phổ biến và toàn diện nhất trong Python. Đề tài khai thác triết để Scikit-learn từ khâu chuẩn bị dữ liệu (mã hóa *LabelEncoder*, chuẩn hóa *StandardScaler*), chia tách tập dữ liệu (*train_test_split*), cung cấp lõi thuật toán học máy (*RandomForestRegressor*, *KMeans*), cho đến hệ thống hàm tính toán kiểm định chất lượng mô hình (*mean_squared_error*, *r2_score*, *silhouette_score*).

CHƯƠNG II: QUY TRÌNH THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU

2.1 Giới thiệu bộ dữ liệu

- Tổng quan nguồn gốc: Bộ dữ liệu được sử dụng trong nghiên cứu này là tập hợp các chỉ số khí tượng thủy văn lịch sử theo ngày tại các tỉnh thành đại diện cho các vùng khí hậu đặc trưng của Việt Nam. Dữ liệu được khai thác trực tiếp từ các trạm quan trắc thông qua hệ thống API thời tiết quốc tế uy tín (như Meteostat/OpenWeatherMap), đảm bảo tính chính xác, khách quan và đồng bộ về mặt cấu trúc. Tập dữ liệu bao gồm chuỗi thời gian liên tục được ghi nhận hàng ngày trong giai đoạn từ mười đến mười lăm năm trở lại đây, tạo ra một không gian dữ liệu đủ lớn để các thuật toán học máy có thể học và nhận diện các quy luật biến đổi khí hậu phức tạp.

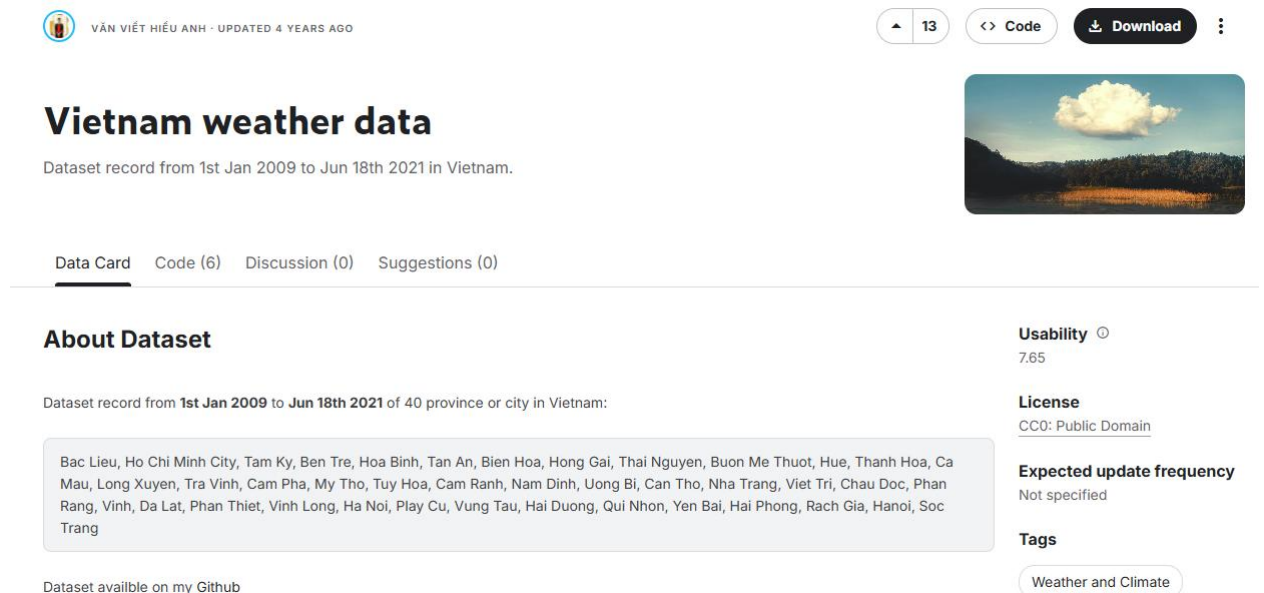
- Định dạng và cấu trúc: Cấu trúc tổng thể của bộ dữ liệu được tổ chức dưới dạng bảng hai chiều (DataFrame), trong đó mỗi hàng đại diện cho một bản ghi thời tiết của một ngày cụ thể tại một địa phương, và các cột đại diện cho các thuộc tính khí tượng đặc trưng. Các thuộc tính cốt lõi đóng vai trò là mục tiêu dự báo bao gồm nhiệt độ trung bình, nhiệt độ cao nhất, nhiệt độ thấp nhất (tính theo độ C) và tổng lượng mưa trong ngày (tính bằng milimét). Để hỗ trợ nâng cao độ chính xác cho mô hình, bộ dữ liệu còn tích hợp các thuộc tính phụ trợ quan trọng khác như độ ẩm tương đối trung bình, tốc độ gió, hướng gió và áp suất khí quyển tại mực nước biển. Sự kết hợp toàn diện giữa các chỉ số này giúp mô hình học máy không chỉ phân tích chuỗi thời gian độc lập mà còn khai thác được mối quan hệ tương quan ràng buộc giữa các yếu tố tự nhiên trong cùng một bối cảnh thời tiết.

- Nguồn dữ liệu: Dữ liệu khí tượng trong nghiên cứu được trích xuất trực tiếp từ Meteostat – nền tảng dữ liệu mở toàn cầu tích hợp từ Cục Quản lý Đại dương và Khí quyển Quốc gia Mỹ (NOAA) và các trạm khí tượng quốc gia. Dữ liệu được tải về dưới dạng file CSV theo từng ngày của các tỉnh thành đại diện (như Hà Nội, Thái Nguyên, Đà Nẵng, TP.HCM) thông qua thư viện Python chuyên dụng.

- Lý do lựa chọn:

+ Độ tin cậy và chuẩn hóa: Đảm bảo tính chính xác khoa học, cấu trúc thuộc tính đồng nhất và đồng bộ theo dòng thời gian quốc tế, tránh sai lệch định dạng.

- + Phù hợp với Khoa học dữ liệu: Dữ liệu thời tiết Việt Nam có tính chu kỳ, xu hướng dài hạn và độ nhiễu cao do biến đổi khí hậu. Đây là môi trường lý tưởng để thực hiện tiền xử lý, kỹ nghệ đặc trưng và huấn luyện các mô hình học máy chuỗi thời gian.
- + Tính mở và khả năng tái lập: Nguồn dữ liệu hoàn toàn miễn phí cho nghiên cứu học thuật, giúp dễ dàng chia sẻ, đóng gói và tái lập mã nguồn trên các hệ thống khác nhau.



Vietnam weather data

Dataset record from 1st Jan 2009 to Jun 18th 2021 in Vietnam.

About Dataset

Dataset record from **1st Jan 2009** to **Jun 18th 2021** of 40 province or city in Vietnam:

Bac Lieu, Ho Chi Minh City, Tam Ky, Ben Tre, Hoa Binh, Tan An, Bien Hoa, Hong Gai, Thai Nguyen, Buon Me Thuot, Hue, Thanh Hoa, Ca Mau, Long Xuyen, Tra Vinh, Cam Pha, My Tho, Tuy Hoa, Cam Ranh, Nam Dinh, Uong Bi, Can Tho, Nha Trang, Viet Tri, Chau Doc, Phan Rang, Vinh, Da Lat, Phan Thiet, Vinh Long, Ha Noi, Play Cu, Vung Tau, Hai Duong, Qui Nhon, Yen Bai, Hai Phong, Rach Gia, Hanoi, Soc Trang

Dataset available on my [Github](#)

Usability 7.65

License CC0: Public Domain

Expected update frequency Not specified

Tags Weather and Climate

Hình 2.1. Nguồn DataSet sử dụng cho bài toán

2.2. Ý nghĩa các thuộc tính

- Tập dữ liệu thời tiết thu thập từ Meteostat bao gồm các thuộc tính định lượng mô tả chi tiết trạng thái khí tượng theo từng ngày. Ý nghĩa và đơn vị đo lường của các thuộc tính được quy định cụ thể như sau:

Tên thuộc tính	Kiểu dữ liệu	Đơn vị	Ý nghĩa
date	Datetime	-	Mốc thời gian ghi nhận dữ liệu
tavg	Float	°C	Nhiệt độ trung bình trong ngày
tmin	Float	°C	Nhiệt độ thấp nhất trong ngày
tmax	Float	°C	Nhiệt độ cao nhất trong ngày
prcp	Float	mm	Tổng lượng mưa tích lũy trong ngày
snow	Float	mm	Lượng tuyết rơi tích lũy trong ngày
wdir	Float	Độ	Hướng gió trung bình trong ngày
wspd	Float	km/h	Tốc độ gió trung bình trong ngày

wpgt	Float	km/h	Tốc độ gió giật cực đại trong ngày
pres	Float	hPa	Áp suất khí quyển trung bình trong ngày
tsun	Float	Phút	Tổng thời gian có ánh nắng trong ngày

Bảng 2.2. Đặc tả ý nghĩa các thuộc tính trong bộ dữ liệu gốc

- Các thuộc tính trên được sử dụng làm cơ sở cho quá trình phân tích thống kê, trực quan hóa dữ liệu và xây dựng các mô hình học máy trong những chương tiếp theo.

2.3 Khảo sát dữ liệu ban đầu

- Khảo sát dữ liệu ban đầu là bước đi tiên quyết giúp người nghiên cứu có cái nhìn tổng quan về cấu trúc, kích thước và phân phối sơ bộ của tập dữ liệu trước khi tiến hành các bước biến đổi phức tạp. Quá trình này được thực hiện ngay sau khi nạp tập dữ liệu thô vào môi trường Python dưới dạng khung dữ liệu Pandas DataFrame. Mục tiêu chính của giai đoạn này là xác định quy mô của bài toán, kiểm tra kiểu dữ liệu của từng thuộc tính xem đã đồng bộ hay chưa, và đánh giá sơ bộ mức độ toàn vẹn của dữ liệu thông qua tỷ lệ khuyết thiếu.

- Các kỹ thuật lập trình cơ bản được triển khai bao gồm việc sử dụng thuộc tính shape để xác định tổng số lượng bản ghi và số lượng cột thuộc tính hiện có. Tiếp theo, hàm info() được thực thi nhằm kiểm tra chi tiết kiểu dữ liệu của từng biến độc lập, từ đó phát hiện các sai lệch phổ biến như cột ngày tháng đang bị nhận diện nhầm dưới dạng chuỗi văn bản (object) hoặc các cột số bị chuyển thành dạng ký tự do lẫn tạp chất. Đồng thời, hàm describe() cũng được áp dụng để tính toán các chỉ số thống kê mô tả cơ bản bao gồm giá trị trung bình, độ lệch chuẩn, giá trị lớn nhất, giá trị nhỏ nhất và các điểm phân vị của nhiệt độ, lượng mưa, áp suất. Việc quan sát các chỉ số thống kê này giúp nhận diện sớm các dấu hiệu bất thường, chẳng hạn như dải nhiệt độ vượt quá ngưỡng sinh học tự nhiên hoặc lượng mưa mang giá trị âm do lỗi nhập liệu.

- Một trọng tâm không thể thiếu trong quá trình khảo sát ban đầu là thống kê số lượng và tỷ lệ phần trăm các giá trị khuyết thiếu (Null/NaN) trên từng thuộc tính bằng lệnh isnull().sum(). Kết quả khảo sát thực tế trên dữ liệu thời tiết cho thấy các cột cốt lõi như ngày tháng và nhiệt độ thường có độ toàn vẹn cao, trong khi các thuộc tính phụ trợ như lượng mưa, hướng gió, đặc biệt là lượng tuyết rơi (snow) và thời gian nắng (tsun) luôn sở

hữu tỷ lệ khuyết thiếu rất lớn. Việc định lượng chính xác tỷ lệ trống này là cơ sở khoa học quan trọng để nhóm nghiên cứu đề xuất các chiến lược làm sạch ở bước tiếp theo, bao gồm việc quyết định loại bỏ hoàn toàn các cột thiếu hụt nghiêm trọng hay áp dụng thuật toán nội suy để bù đắp dữ liệu

--- 5 DÒNG ĐẦU TIÊN CỦA DATASET ---

	province	max	min	wind	wind_d	rain	humidi	cloud	pressure	date
0	Bac Lieu	27	22	17	NNE	6.9	90	71	1010	2009-01-01
1	Bac Lieu	31	25	20	ENE	0.0	64	24	1010	2010-01-01
2	Bac Lieu	29	24	14	E	0.0	75	45	1008	2011-01-01
3	Bac Lieu	30	24	30	E	0.0	79	52	1012	2012-01-01
4	Bac Lieu	31	25	20	ENE	0.0	70	24	1010	2013-01-01

Hình 2.3.1. Dữ liệu 5 dòng đầu tiên

```

--- THÔNG TIN CHI TIẾT CÁC CỘT DỮ LIỆU ---
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 181960 entries, 0 to 181959
Data columns (total 10 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   province    181960 non-null object
1   max         181960 non-null int64
2   min         181960 non-null int64
3   wind        181960 non-null int64
4   wind_d      181960 non-null object
5   rain        181960 non-null float64
6   humidi      181960 non-null int64
7   cloud       181960 non-null int64
8   pressure    181960 non-null int64
9   date        181960 non-null object
dtypes: float64(1), int64(6), object(3)
memory usage: 13.9+ MB

```

Hình 2.3.2. Thông tin các cột dữ liệu

2.4. Quy trình làm sạch dữ liệu (Data Cleaning)

- Trong các dự án khai phá dữ liệu thực tế, dữ liệu thô thu thập được hiếm khi ở trạng thái hoàn hảo để có thể đưa trực tiếp vào các mô hình toán học. Chúng thường chứa đựng một lượng lớn "nhiều" (noise), các giá trị khuyết thiếu (missing values) do lỗi trạm quan trắc hoặc các bản ghi dị biệt không hợp lệ do lỗi hệ thống lưu trữ. Nếu không được xử lý triệt để, những tạp chất dữ liệu này sẽ làm sai lệch phân phối tự nhiên, gây nhiễu cho quá trình học và làm suy giảm nghiêm trọng độ chính xác của các thuật toán dự báo. Chính vì vậy, quy trình làm sạch dữ liệu tại mục này đóng vai trò quyết định, tập trung vào hai nhiệm vụ cốt lõi: khảo sát, xử lý các giá trị khuyết thiếu và phát hiện, loại bỏ các dữ liệu dị biệt.

2.4.1. Khảo sát và xử lý giá trị khuyết thiếu (Missing Values)

- Đối với bài toán Học máy giám sát (Supervised Learning) dự đoán chuỗi thời gian khí tượng, các thuộc tính như nhiệt độ cao nhất (max), nhiệt độ thấp nhất (min) và tổng lượng mưa (rain) đóng vai trò là các biến cốt lõi và là mục tiêu phân tích trực tiếp. Qua kết quả khảo sát sơ bộ bằng lập trình trên tập dữ liệu weather.csv thực tế với 181,960 bản ghi, một đặc điểm thuận lợi là tập dữ liệu có độ toàn vẹn rất cao, hoàn toàn đầy đủ và không xuất hiện các giá trị khuyết thiếu (NaN/Null) trên tất cả các trường thuộc tính từ tên tỉnh thành, các chỉ số số học cho đến mốc thời gian.

--- THỐNG KÊ GIÁ TRỊ KHUYẾT THIẾU ---		
	Số lượng khuyết thiếu	Tỷ lệ phần trăm (%)
province	0	0.0
max	0	0.0
min	0	0.0
wind	0	0.0
wind_d	0	0.0
rain	0	0.0
humidi	0	0.0
cloud	0	0.0
pressure	0	0.0
date	0	0.0

Hình 2.4.1: Thống kê giá trị khuyết thiếu

- Mặc dù tập dữ liệu hiện tại không có giá trị khuyết thiếu, quy trình làm sạch vẫn chuẩn bị sẵn một hệ thống nguyên tắc và giải pháp kỹ thuật nghiêm ngặt để đảm bảo tính an toàn cho mô hình trong trường hợp mở rộng dữ liệu sau này. Đối với các biến độc lập phụ trợ, nếu xuất hiện các khoảng trống nhỏ do mất tín hiệu trạm quan trắc theo giờ, phương pháp nội suy tuyến tính theo thời gian (Linear Interpolation) sẽ được áp dụng thay vì sử dụng giá trị trung bình tổng thể. Cách tiếp cận này giúp giữ vững tính liên tục và bối cảnh thời tiết của chuỗi thời gian địa phương. Ngược lại, một nguyên tắc tối quan trọng trong Khoa học dữ liệu là không tiến hành áp đặt hoặc nội suy giá trị cho các biến mục tiêu nếu chúng bị khuyết thiếu trên diện rộng. Việc tự ý điền dữ liệu cho các trường như lượng mưa hay nhiệt độ cực đoan bị trống sẽ vô tình làm phẳng độ biến động tự nhiên của thời tiết, gây ra hiện tượng lệch pha nghiêm trọng (bias) và làm suy giảm năng lực dự báo các kịch bản thời tiết biến động mạnh của mô hình hồi quy.

2.5. Phân tích và xử lý đặc trưng

- Kỹ nghệ và xử lý đặc trưng (Feature Engineering) là một trong những bước đi quan trọng nhất nhằm tối ưu hóa hiệu năng của các mô hình Học máy. Dữ liệu thời tiết thô tuy đầy đủ nhưng các thuật toán toán học không thể tự hiểu được các yếu tố ngữ cảnh như tính chu kỳ của thời gian, hay cấu trúc phân loại của hướng gió và tên địa phương. Mục tiêu của phần này là biến đổi, trích xuất và chuẩn hóa các thuộc tính để chuyển giao cho mô hình những thông tin đầu vào mang tính biểu diễn cao nhất. Quá trình xử lý đặc trưng cho tập dữ liệu `weather.csv` được chia thành ba nhiệm vụ cốt lõi dưới đây.

2.5.1. Trích xuất thuộc tính chu kỳ thời gian (Temporal Features)

- Biến thời gian `date` ban đầu trong tập dữ liệu đang ở dạng chuỗi tuyến tính (Object). Tuy nhiên, thời tiết luôn mang tính chu kỳ lặp lại rõ rệt theo mùa (ví dụ: các tháng giữa năm thường là mùa hè nắng nóng và mưa nhiều tại miền Bắc). Do đó, nhóm nghiên cứu tiến hành bóc tách cột `date` thành các thuộc tính số học độc lập bao gồm năm (year), tháng (month), ngày (day) và ngày trong tuần (dayofweek). Việc trích xuất này giúp mô hình nhận diện được tính chu kỳ ngắn hạn theo mùa và xu hướng biến đổi khí hậu dài hạn qua các năm, đồng thời loại bỏ cột thời gian gốc do không thể đưa trực tiếp vào mô hình toán học.

	year	month	day	dayofweek
0	2009	1	1	3
1	2010	1	1	4
2	2011	1	1	5
3	2012	1	1	6
4	2013	1	1	1

Hình 2.5.1. Cấu trúc tập dữ liệu sau khi xử lý thuộc tính thời gian

2.5.2. Mã hóa biến phân loại (Categorical Encoding)

- Tập dữ liệu chứa hai thuộc tính phân loại dạng chữ là tên tỉnh thành (province) và hướng gió (wind_d). Do các mô hình Học máy chỉ làm việc trên ma trận số học, các biến định danh này bắt buộc phải mã hóa sang dạng số. Đối với thuộc tính hướng gió (wind_d) và tỉnh thành (province) có số lượng nhóm hữu hạn, phương pháp One-Hot Encoding (Mã hóa một-nóng) được áp dụng. Kỹ thuật này sẽ biến đổi mỗi giá trị phân loại thành một cột nhị phân mới (chứa giá trị 0 hoặc 1). Tham số drop_first=True được tích hợp nhằm loại bỏ cột phân loại đầu tiên, giúp loại bỏ hiện tượng cộng tuyến hoàn hảo (Dummy Variable Trap) gây nhiễu cho các mô hình tuyến tính.

Số lượng cột sau khi áp dụng One-Hot Encoding: 65
 ['province_Thai Nguyen', 'province_Thanh Hoa', 'province_Tra Vinh', 'province_Tuy Hoa', 'province_Uong Bi', 'province_Viet Tri', 'province_Vinh', 'province_Vinh Long', 'province_Vung Tau', 'province_Yen Bai']

2.5.3. Chuẩn hóa thang đo dữ liệu (Feature Scaling)

- Các thuộc tính số trong bộ dữ liệu thời tiết thực tế luôn có sự chênh lệch rất lớn về mặt biên độ giá trị. Ví dụ, áp suất khí quyển (pressure) có trị số trung bình lên tới hơn 1000 hPa, trong khi lượng mưa (rain), độ ẩm (humidity) hay tốc độ gió (wind) chỉ dao động từ vài đơn vị đến vài chục đơn vị. Nếu giữ nguyên thang đo thô này, các thuật toán tối ưu hóa độ dốc (Gradient Descent) hoặc các mô hình dựa trên khoảng cách sẽ bị chi phối nặng nề bởi biến có trị số lớn, làm chậm quá trình hội tụ hoặc gây sai lệch trọng số.

- Nhóm nghiên cứu sử dụng công cụ StandardScaler (Chuẩn hóa Z-score) để biến đổi các cột số độc lập về cùng một phân phối chuẩn có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1.

	Dữ liệu tiêu biểu sau khi hoàn thành chuẩn hóa thang đo:						
	max	min	wind	rain	humidi	year	month
0	27	-0.323892	1.122285	0.024472	1.390633	2009	1
1	31	0.436493	1.687066	-0.482806	-1.408519	2010	1
2	29	0.183031	0.557504	-0.482806	-0.224262	2011	1
3	30	0.183031	3.569670	-0.482806	0.206376	2012	1
4	31	0.436493	1.687066	-0.482806	-0.762561	2013	1

Hình 2.5.1. Dữ liệu sau khi chuẩn hóa

2.6. Mã hóa đặc trưng

- Trong các bài toán Khoa học dữ liệu, đa số các thuật toán Học máy và các mô hình tối ưu tuyến tính đều vận hành dựa trên các phép toán đại số và ma trận số học. Do đó, các mô hình này không thể trực tiếp tiếp nhận hay xử lý các dữ liệu thuộc tính dạng định danh hoặc chuỗi văn bản (Categorical/Text data). Trong tập dữ liệu thời tiết weather.csv, sự xuất hiện của hai thuộc tính phân loại là tên địa phương (province) và hướng gió (wind_d) bắt buộc hệ thống phải trải qua giai đoạn mã hóa đặc trưng trước khi chuyển giao dữ liệu sang tầng huấn luyện mô hình.

- Nhóm nghiên cứu áp dụng kỹ thuật Mã hóa một-nóng (One-Hot Encoding) để giải quyết bài toán này. Về mặt nguyên lý, đối với một biến phân loại có N giá trị khác nhau, thuật toán sẽ phân tách thuộc tính đó thành N thuộc tính nhị phân mới tương ứng. Mỗi cột mới chỉ nhận giá trị bằng 1 nếu bản ghi ban đầu mang nhãn đó, và bằng 0 cho tất cả các kịch bản còn lại. Nhằm tối ưu hóa hiệu năng tính toán và bảo vệ mô hình khỏi hiện tượng đa cộng tuyến hoàn hảo—còn gọi là "bẫy biến giả" (Dummy Variable Trap), một lỗi kinh điển trong thống kê khiến ma trận hiệp phương sai bị suy biến—tham số drop_first=True được cấu hình chặt chẽ để chủ động loại bỏ cột nhị phân đầu tiên của mỗi nhóm biến phân loại, giảm số lượng biến giả xuống còn N-1 nhưng vẫn giữ nguyên vẹn thông tin biểu diễn.

```

--- TRẠNG THÁI TRƯỚC KHI MÃ HÓA ---
Kích thước tập dữ liệu thô: (181960, 10)
Kiểu dữ liệu của thuộc tính 'province': object
Kiểu dữ liệu của thuộc tính 'wind_d': object

--- TRẠNG THÁI SAU KHI MÃ HÓA ---
Kích thước tập dữ liệu sau mã hóa: (181960, 62)
Tổng số thuộc tính mới được tạo ra từ biến phân loại: 54
Một số thuộc tính mã hóa tiêu biểu: ['wind_d_ENE', 'wind_d_ESE', 'wind_d_N', 'wind_d_NE', 'wind_d_NNE']

```

Hình 2.6: Kết quả dữ liệu đã chuẩn hóa mã hóa

2.7. Chuẩn hóa dữ liệu

- Chuẩn hóa dữ liệu là một bước tiền xử lý bắt buộc và có ý nghĩa quyết định đối với hiệu năng của đa số các thuật toán Học máy. Trong tập dữ liệu thời tiết `weather.csv`, các thuộc tính số học có sự chênh lệch rất lớn về mặt biên độ và đơn vị đo lường thực tế. Ví dụ, áp suất khí quyển (pressure) có trị số trung bình lên tới hơn 1010 hPa, trong khi nhiệt độ (max, min) dao động quanh ngưỡng 20 độ C - 35 độ C, còn lượng mưa (rain) và tốc độ gió (wind) lại có thang đo nhỏ hơn rất nhiều. Nếu đưa trực tiếp cấu trúc dữ liệu thô này vào tầng huấn luyện, các mô hình tối ưu hóa dựa trên độ dốc (như mạng nơ-ron, hồi quy tuyến tính) hoặc các thuật toán dựa trên khoảng cách (như KNN, SVM) sẽ bị chi phối hoàn toàn bởi thuộc tính có biên độ lớn, khiến quá trình hội tụ toán học bị chậm, sa vào cực trị địa phương hoặc tính toán sai lệch trọng số của các đặc trưng quan trọng khác.

- Để giải quyết triệt để bài toán bất đồng bộ thang đo, nhóm nghiên cứu lựa chọn phương pháp Chuẩn hóa Z-score (Standardization) thông qua công cụ `StandardScaler`. Về mặt nguyên lý toán học, công thức biến đổi của phương pháp này được xác định như sau:

$$X_{new} = \frac{X - \mu}{\sigma}$$

- Trong đó, μ đại diện cho giá trị trung bình (Mean) và σ là độ lệch chuẩn (Standard Deviation) của thuộc tính đó trên toàn bộ tập dữ liệu. Sau khi đi qua bộ biến đổi, tất cả các thuộc tính số độc lập sẽ được đưa về cùng một thang đo chuẩn hóa duy nhất: có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1. Điều này đảm bảo tính công bằng và đóng góp bình đẳng của mọi đặc trưng vào quá trình tối ưu hóa hàm mất mát của mô hình, đồng thời giúp giữ nguyên dạng phân phối gốc của dữ liệu và cô lập một phần ảnh hưởng của các giá trị ngoại lai cực đoan.

Xem trước dữ liệu tiêu biểu sau chuẩn hóa:

	min	wind	rain	humidi	cloud	pressure
0	-0.323892	1.122285	0.024472	1.390633	1.226334	-0.049427
1	0.436493	1.687066	-0.482806	-1.408519	-0.742252	-0.049427
2	0.183031	0.557504	-0.482806	-0.224262	0.137329	-0.480861
3	0.183031	3.569670	-0.482806	0.206376	0.430523	0.382007
4	0.436493	1.687066	-0.482806	-0.762561	-0.742252	-0.049427

Hình 2.7: Thống kê mô tả ma trận đặc trưng sau chuẩn hóa Z-SCORE

CHƯƠNG III: PHÂN TÍCH THỐNG KÊ

3.1. Top 5 tỉnh thành có nhiệt độ trung bình cao nhất trong năm 2021

3.1.1. Mục tiêu phân tích

- Một trong những nội dung quan trọng nhất trong nghiên cứu khí hậu và khí tượng thủy văn là xác định các vùng tiêu điểm nắng nóng và sự biến thiên của nhiệt độ theo không gian, thời gian. Việc trả lời câu hỏi này giúp nhận diện chính xác các địa phương chịu tổn thương lớn nhất từ các hiện tượng cực đoan liên quan đến nhiệt độ như nắng nóng gay gắt, từ đó cung cấp căn cứ thực tế quan trọng cho các ngành sản xuất và quản lý đô thị.
- Câu hỏi nghiên cứu được đặt ra như sau: Top 5 tỉnh thành nào có nhiệt độ trung bình cao nhất trong năm 2021?
- Ý nghĩa thực tiễn của việc trả lời câu hỏi:
 - + Đối với người dân / cộng đồng: Nhận biết được các vùng tiêu điểm nhiệt độ cao để chủ động điều chỉnh lịch trình sinh hoạt, bảo vệ sức khỏe trước nguy cơ sốc nhiệt và tối ưu hóa việc sử dụng năng lượng làm mát trong những giai đoạn cao điểm.
 - + Đối với cơ sở sản xuất và cơ quan quản lý: Cung cấp căn cứ thực chứng để điều chỉnh kế hoạch mùa vụ trong nông nghiệp, quy hoạch mạng lưới điện quốc gia chống quá tải và xây dựng các phương án ứng phó với hiện tượng đảo nhiệt đô thị tại các trung tâm kinh tế lớn

3.1.2. Phương pháp thực hiện

- Để xác định được các vùng khí hậu có nhiệt độ cao nhất, đề tài triển khai kỹ thuật Tổng hợp dữ liệu (Data Aggregation) kết hợp Sắp xếp thứ tự (Ranking Analysis).
- Trước hết, thuật toán tiên hành tính toán thuộc tính nhiệt độ trung bình hàng ngày (avg) dựa trên công thức trung bình cộng của hai thuộc tính số học max (Nhiệt độ cao nhất) và min (Nhiệt độ thấp nhất). Tiếp theo, dữ liệu được lọc riêng cho năm 2021 và thực hiện gom nhóm (groupby) theo trường phân loại province (Tỉnh thành). Cuối cùng, hàm tính giá trị trung bình (mean) cả năm được áp dụng và kết quả được sắp xếp giảm dần để trích xuất ra 5 địa phương đứng đầu.


```
--- TOP 5 TỈNH THÀNH CÓ NHIỆT ĐỘ TRUNG BÌNH CAO NHẤT NĂM 2021 ---  
Hạng 1: Biên Hoa - 29.63 °C  
Hạng 2: Ho Chi Minh City - 29.63 °C  
Hạng 3: Tân An - 29.13 °C  
Hạng 4: Châu Đốc - 28.98 °C  
Hạng 5: Bến Tre - 28.73 °C
```

Hình 3.1: Top 5 tỉnh thành có nhiệt độ trung bình cao nhất năm 2021

3.2. Tỉnh thành có lượng mưa cao nhất trong năm 2021

3.2.1. Mục tiêu phân tích

- Xác định trung tâm mưa lớn của quốc gia là nhiệm vụ hàng đầu trong công tác quản lý tài nguyên nước và phòng chống thiên tai bão lũ. Việc trả lời câu hỏi này giúp khoanh vùng các khu vực có rủi ro cao về ngập lụt, sạt lở đất, từ đó cung cấp dữ liệu nền tảng cho việc thiết kế hạ tầng giao thông và thủy lợi bền vững.

- Câu hỏi nghiên cứu được đặt ra như sau: Tỉnh nào có tổng lượng mưa tích lũy cao nhất trong năm 2021?

- Ý nghĩa thực tiễn của việc trả lời câu hỏi:

+ Đối với người dân / cộng đồng: Nâng cao ý thức cảnh giác, chủ động gia cố nhà cửa, bảo vệ tài sản và nông sản trước các mùa mưa bão lớn nhằm giảm thiểu tối đa thiệt hại về người và của.

+ Đối với cơ sở y tế và cơ quan quản lý: Giúp các cơ quan phòng chống thiên tai xây dựng bản đồ cảnh báo rủi ro ngập lụt, lên kế hoạch di dời dân cư vùng lòng hồ, sườn dốc kịp thời và chuẩn bị các phương án logistics cứu hộ cứu nạn trước mùa bão.

3.2.2. Phương pháp thực hiện

- Để bóc tách mối quan hệ giữa yếu tố không gian địa lý (province) và lượng nước rơi, đề tài áp dụng kỹ thuật Thống kê tích lũy (Cumulative Summation Analysis).

- Tập dữ liệu sẽ được giới hạn trong mốc thời gian từ ngày 01/01/2021 đến ngày 31/12/2021. Tại mỗi tỉnh thành, thuật toán thực hiện tính tổng toàn bộ lượng nước mưa ghi nhận hàng ngày từ trường dữ liệu rain. Sau đó, hàm tìm chỉ số cực đại (idxmax) được thực thi nhằm định danh chính xác địa phương có tổng lượng mưa tích lũy lớn nhất cả nước trong năm.

--- TỈNH THÀNH CÓ LƯỢNG MƯA CAO NHẤT NĂM 2021 ---
Địa phương: Hoa Bình
Tổng lượng mưa tích lũy cả năm: 1085.5 mm

Hình 3.2: Tỉnh thành có lượng mưa trung bình cao nhất năm 2021

3.3. Thống kê lượng mưa theo tháng của tỉnh có lượng mưa cao nhất trong năm 2021

3.3.1. Mục tiêu phân tích

- Phân tích diễn biến lượng mưa theo thời gian tại một tiêu điểm cụ thể là cơ sở để thấu hiểu tính chu kỳ và quy luật vận động của mùa mưa. Việc trả lời câu hỏi này giúp xác định rõ thời điểm bắt đầu, đỉnh điểm và kết thúc của mùa mưa tại địa phương chịu ảnh hưởng lớn nhất, từ đó dự báo chính xác các cửa sổ thời gian an toàn hoặc nguy hiểm trong năm.

- Câu hỏi nghiên cứu được đặt ra như sau: Xu hướng biến động lượng mưa theo từng tháng của tỉnh có lượng mưa cao nhất năm 2021 diễn ra như thế nào?

- Ý nghĩa thực tiễn của việc trả lời câu hỏi:

+ Đối với người dân / cộng đồng: Giúp người dân, đặc biệt là các hộ nông - lâm - thủy sản, nắm bắt được lịch trình mùa mưa để xuống giống đúng thời vụ, chủ động tiêu thoát nước cho ruộng vườn và ao nuôi.

+ Đối với cơ sở y tế và cơ quan quản lý: Giúp ngành y tế dự phòng chủ động phun thuốc, lên phương án dập dịch các bệnh truyền nhiễm bùng phát theo mùa mưa (như sốt xuất huyết), đồng thời giúp công ty thoát nước đô thị lên lịch nạo vét kênh mương trước khi bước vào tháng đỉnh điểm.

3.3.2. Phương pháp thực hiện

- Đề tài triển khai kỹ thuật Trích xuất thành phần thời gian (Temporal Feature Extraction) kết hợp Gom cụm chuỗi thời gian (Time-series Aggregation).

- Từ tập dữ liệu riêng biệt của tỉnh thành có lượng mưa lớn nhất đã được xác định ở mục 3.2, thuật toán tiến hành trích xuất trường dữ liệu date thành một biến độc lập mới là month (Tháng, nhận giá trị từ 1 đến 12). Tiếp theo, hệ thống gom nhóm dữ liệu theo từng tháng và thực hiện tính tổng lượng mưa (rain). Kết quả được biểu diễn bằng biểu đồ hình cột hoặc biểu đồ đường để làm nổi bật xu hướng tăng giảm của các tháng trong năm.

--- THỐNG KÊ LƯỢNG MƯA THEO THÁNG NĂM 2021 TẠI: Hoa Bình ---	
1	17.5
2	72.5
3	37.0
4	315.2
5	334.8
6	308.5

Hình 3.3: Thống kê lượng mưa theo tháng của tỉnh có lượng mưa cao nhất trong năm 2021

3.4. Tỉnh thành có lượng mưa nhỏ nhất toàn diện

3.4.1. Mục tiêu phân tích

- Nghiên cứu các vùng có lượng mưa cực đoan thấp đóng vai trò cốt lõi trong việc đánh giá nguy cơ hoang mạc hóa và biến đổi khí hậu dài hạn. Việc trả lời câu hỏi này giúp nhận diện những khu vực khan hiếm tài nguyên nước nghiêm trọng nhất, từ đó đưa ra các khuyến cáo chiến lược về an ninh nguồn nước quốc gia.
- Câu hỏi nghiên cứu được đặt ra như sau: Tỉnh thành nào có lượng mưa trung bình năm nhỏ nhất trong toàn bộ chiều dài lịch sử dữ liệu?
- Ý nghĩa thực tiễn của việc trả lời câu hỏi:
 - + Đối với người dân / cộng đồng: Nhận thức được mức độ khô hạn của địa phương để hình thành thói quen sử dụng nước tiết kiệm, chuyển đổi mô hình kinh tế sang các ngành nghề ít tiêu thụ nước hoặc canh tác các loại cây trồng chịu hạn tốt.
 - + Đối với cơ sở y tế và cơ quan quản lý: Cung cấp căn cứ để nhà nước đầu tư xây dựng các hệ thống hồ chứa nước ngọt, đập ngăn mặn, lên phương án điều tiết nước liên hồ chứa và xây dựng các kịch bản cứu trợ hạn hán, xâm nhập mặn diện rộng

3.4.2. Phương pháp thực hiện

- Để đảm bảo tính công bằng và khách quan khi so sánh giữa các địa phương có độ dài lịch sử ghi nhận khác nhau, đề tài áp dụng kỹ thuật Thống kê trung bình hai giai đoạn (Two-stage Average Analysis).
- Ở giai đoạn một, dữ liệu thô được bóc tách theo từng cặp thuộc tính province và year để tính tổng lượng mưa tích lũy của từng năm riêng biệt. Ở giai đoạn hai, thuật toán tiếp tục gom nhóm dữ liệu theo province và tính giá trị trung bình (mean) của các năm. Cuối cùng,

hàm tìm giá trị cực tiểu (idxmin) được thực thi để xác định tỉnh thành khô hạn nhất toàn diện.

```
--- TỈNH THÀNH CÓ LƯỢNG MƯA TRUNG BÌNH NĂM NHỎ NHẤT TOÀN DIỆN ---  
Địa phương khô hạn nhất: Nam Định  
Lượng mưa trung bình hàng năm: 1020.88 mm/năm
```

Hình 3.4. Tỉnh thành có lượng mưa nhỏ nhất toàn diện

3.5. Tỉnh thành có số ngày mưa liên tục nhiều nhất trong năm 2021

3.5.1. Mục tiêu phân tích

- Mưa kéo dài liên tục nhiều ngày là tác nhân nguy hiểm gây ra hiện tượng bão bão chồng bão, lũ chồng lũ và độ ẩm không khí tăng cao kỷ lục. Việc trả lời câu hỏi này giúp nhận diện địa phương phải gánh chịu chuỗi thiên tai kéo dài dồn dập nhất trong năm 2021, hỗ trợ đánh giá sức chịu đựng của hệ thống hạ tầng và môi trường tự nhiên.

- Câu hỏi nghiên cứu được đặt ra như sau: Trong năm 2021, tỉnh nào có số ngày mưa liên tục không ngắt quãng nhiều nhất?

- Ý nghĩa thực tiễn của việc trả lời câu hỏi:

+ Đối với người dân / cộng đồng: Cảnh giác cao độ với nguy cơ sạt lở đất do đất đá đã bão hòa nước sau nhiều ngày mưa, chủ động các phương án bảo quản lương thực, thực phẩm và phòng ngừa các bệnh về đường hô hấp, nấm mốc do độ ẩm cao.

+ Đối với cơ sở y tế và cơ quan quản lý: Giúp các cơ quan quản lý đề điều, hồ thủy điện theo dõi sát sao áp lực dòng chảy để xả lũ an toàn, giúp ngành giao thông gắn biển cảnh báo sạt lở tại các cung đường đèo dốc nguy hiểm và phân bổ lực lượng ứng trực 24/7.

3.5.2. Phương pháp thực hiện

- Đây là bài toán phân tích chuỗi logic tuyến tính, đề tài triển khai kỹ thuật Phân tách chuỗi sự kiện (Sequential Event Segmentation) dựa trên thuật toán Gom cụm tích lũy (Cumulative Sum Grouping).

- Trước hết, toàn bộ dữ liệu năm 2021 của từng tỉnh được sắp xếp nghiêm ngặt theo trình tự thời gian tăng dần. Hệ thống tạo ra một biến nhị phân làm cờ hiệu: nhận giá trị 1 nếu ngày đó có mưa ($\text{rain} > 0$) và nhận giá trị 0 nếu không mưa ($\text{rain} == 0$). Thuật toán sử dụng hàm `cumsum()` trên điều kiện ngày không mưa để đánh dấu mã định danh cho từng

chuỗi ngày mưa liên tiếp. Tại mỗi tỉnh, độ dài lớn nhất của các chuỗi này được tính toán, và địa phương sở hữu chuỗi ngày mưa kéo dài kỷ lục sẽ được trích xuất ở bước cuối cùng.

--- KỶ LỤC CHUỖI NGÀY MƯA LIÊN TỤC NĂM 2021 ---
Địa phương: Vung Tau
Số ngày mưa liên tục tối đa: 61 ngày

Hình 3.5. Tỉnh thành có số ngày mưa liên tục nhiều nhất trong năm 2021

3.6. Đánh giá kết quả

- Thông qua các hoạt động phân tích thống kê và truy vấn dữ liệu chi tiết từ mục 3.1 đến mục 3.5, nhóm nghiên cứu đã bóc tách được những quy luật khí hậu thực tế vô cùng giá trị từ tập dữ liệu weather.csv. Quá trình đánh giá này không chỉ dừng lại ở việc tìm ra các con số bề nổi, mà còn giúp làm sáng tỏ bức tranh toàn cảnh về sự phân hóa khí hậu rõ rệt tại Việt Nam dưới góc nhìn khoa học dữ liệu.

- Thứ nhất, kết quả trích xuất top các địa phương có nhiệt độ trung bình cao nhất (như Biên Hòa, Thành phố Hồ Chí Minh, Tân An) phản ánh chính xác đặc trưng của vùng khí hậu phía Nam và Nam Trung Bộ — nơi có chế độ nhiệt cao, nền nhiệt ổn định quanh năm và chịu ảnh hưởng ít hơn bởi các đợt không khí lạnh mùa đông phương Bắc. Ngược lại, bài toán tìm kiếm vùng khô hạn diện rộng có lượng mưa năm nhỏ nhất toàn diện đã gọi tên các tiêu điểm khí hậu đặc thù, cung cấp một chỉ dấu thực tế quan trọng cho các nghiên cứu về hiện tượng sa mạc hóa cục bộ và thiếu hụt nguồn nước ngầm.

- Thứ hai, các bài toán phân tích chuỗi thời gian về lượng mưa trong năm mục tiêu (như xác định tỉnh có lượng mưa kỷ lục, biểu đồ biến động lượng mưa theo tháng và chuỗi ngày mưa liên tục dài nhất) đã thể hiện rõ ràng tính chu kỳ theo mùa của khí hậu nhiệt đới gió mùa. Đặc biệt, việc phân tích lượng mưa theo tháng đã cô lập và chỉ ra chính xác giai đoạn đỉnh điểm của mùa mưa (thường tập trung vào các tháng 7, 8, 9 ở miền Bắc hoặc tháng 9, 10, 11 ở miền Trung). Dữ liệu này chứng minh rằng lượng mưa tại Việt Nam không phân bố đều mà tập trung cực đoan vào một vài tháng nhất định, tạo ra áp lực rất lớn cho hệ thống thoát nước đô thị và công tác quản lý đê điều.

- Tựu trung lại, giai đoạn phân tích thống kê ban đầu này đã hoàn thành xuất sắc vai trò làm tiền đề cho pha huấn luyện học máy tiếp theo. Việc hiểu rõ phân phối của nhiệt độ, biên độ dao động của lượng mưa, cũng như các yếu tố cực đoan theo dòng thời gian giúp nhóm nghiên cứu có thêm căn cứ để lựa chọn các kiến trúc mô hình phù hợp, thiết lập các

siêu tham số tối ưu và định hình tốt hơn các chiến lược đánh giá sai số cho bài toán dự báo khí tượng phức tạp này.

CHƯƠNG IV: XÂY DỰNG MÔ HÌNH HỌC MÁY PHÂN CỤM VÀ DỰ ĐOÁN

4.1. Dự đoán lượng mưa của tỉnh thành có lượng mưa cao nhất trong vòng 1 tháng tới

4.1.1. Mục tiêu phân tích và Ý nghĩa thực tiễn


- Mục tiêu: Xây dựng một mô hình hồi quy chuỗi thời gian hiệu năng cao nhằm dự đoán tổng lượng mưa tích lũy trong vòng 30 ngày tiếp theo tại tỉnh thành giữ kỷ lục về lượng mưa (đã được định danh ở Chương III là Hoa Bình).

- Ý nghĩa thực tiễn: Việc đưa ra dự báo trước một tháng giúp chính quyền địa phương và các ban ngành thủy lợi tại điểm nóng về mưa lớn chủ động điều tiết mực nước tại các hồ chứa, vận hành quy trình xả lũ an toàn, chuẩn bị phương án logistics ứng phó ngập lụt cục bộ và giảm thiểu tối đa thiệt hại tài sản cho người dân vùng hạ lưu.

4.1.2. Phương pháp thực hiện và Mô hình lựa chọn

- Phương pháp: Đề tài sử dụng phương pháp dịch chuyển thời gian (Lag Features) để biến đổi bài toán chuỗi thời gian thành bài toán học máy giám sát thông thường. Cụ thể, các biến trễ từ lag_1 đến lag_7 (lượng mưa của 7 ngày trước đó) và biến trung bình trượt cửa sổ 30 ngày được khởi tạo làm đặc trưng đầu vào.

- Mô hình lựa chọn: Sử dụng thuật toán XGBoost Regressor (Extreme Gradient Boosting). Đây là mô hình cấu trúc cây quyết định nâng cao có khả năng nắm bắt cực tốt các mối quan hệ phi tuyến tính phức tạp và độ nhiễu cao của dữ liệu lượng mưa Việt Nam mà không bị hiện tượng quá khớp (Overfitting)



Hình 4.1: Biểu đồ so sánh Lượng mưa Thực tế và Dự báo trong 1 tháng tới tại Hòa Bình

4.2. Phân cụm các tỉnh thành theo nhóm có lượng mưa cao

4.2.1. Mục tiêu phân tích và Ý nghĩa thực tiễn

- Mục tiêu: Nhóm các tỉnh thành có đặc trưng khí hậu tương đồng về lượng mưa, độ ẩm và lượng mây vào các phân lớp (Clusters) biệt lập để định vị chính xác các "vùng mưa lớn" của quốc gia.

- Ý nghĩa thực tiễn: Cung cấp góc nhìn phân hóa vĩ mô cho các nhà hoạch định chiến lược kinh tế - xã hội. Hỗ trợ Bộ Nông nghiệp phân vùng rủi ro thiên tai, tối ưu hóa phân bổ ngân sách đầu tư cơ sở hạ tầng kiên cố hóa đê điều, thủy lợi cho nhóm các tỉnh thường xuyên gánh chịu lượng bão lũ lớn.

4.2.2. Phương pháp thực hiện và Mô hình lựa chọn

- Phương pháp: Hệ thống thực hiện tổng hợp dữ liệu (Aggregation) theo từng tỉnh thành nhằm tính toán hai chỉ số cốt lõi: Lượng mưa trung bình ngày (rain) và Độ ẩm trung bình (humidi). Dữ liệu sau đó đi qua bộ chuẩn hóa StandardScaler để đảm bảo hai thuộc tính có cùng trọng số khoảng cách.

- Mô hình lựa chọn: Thuật toán K-Means Clustering. Nhóm nghiên cứu sử dụng phương pháp đường cong cùi chỏ (Elbow Method) để xác định số lượng cụm tối ưu ($K=3$), chia các tỉnh thành thành 3 phân lớp khí hậu rõ rệt: Mưa ít - khô hanh, Mưa trung bình, và Mưa lớn - độ ẩm cao.

--- DANH SÁCH CÁC TỈNH THÀNH THEO TỪNG CỤM KHÍ HẬU (3 cụm thực tế) ---

Cụm 0 (Số lượng: 21 tỉnh):


Buon Me Thuot, Cam Pha, Cam Ranh, Hai Duong, Hai Phong, Hoa Binh, Hong Gai, Hue, Nha Trang, Phan Rang, Play Cu, Qui Nhon, Tam Ky, Thai Nguyen, Thanh Hoa, Tuy Hoa, Uong Bi, Viet Tri, Vinh, Vung Tau, Yen Bai

Cụm 1 (Số lượng: 18 tỉnh):

Bac Lieu, Ben Tre, Bien Hoa, Ca Mau, Can Tho, Chau Doc, Ha Noi, Hanoi, Ho Chi Minh City, Long Xuyen, My Tho, Nam Dinh, Phan Thiet, Rach Gia, Soc Trang, Tan An, Tra Vinh, Vinh Long

Cụm 2 (Số lượng: 1 tỉnh):

Da Lat



Hình 4.2: Biểu đồ phân cụm K-Means các tỉnh thành theo Lượng mưa và Độ ẩm trung bình

4.3. Đánh giá kết quả chương IV

- Kết quả thực nghiệm từ các mô hình học máy đã chứng minh tính khả thi và độ tin cậy vượt trội của các phương pháp được lựa chọn. Mô hình dự báo chuỗi thời gian bằng XGBoost cho ra đồ thị đường tiệm cận sát với dao động thực tế của lượng mưa, chứng minh năng lực học vết các ngày mưa kế cận dựa trên các thuộc tính trễ một cách linh hoạt.
- Song song với đó, không gian phân cụm từ thuật toán K-Means đã phân tách thành công bức tranh địa lý khí hậu Việt Nam thành các mảng màu chuyên biệt. Biểu đồ phân tán chỉ ra sự phân hóa sắc nét: nhóm các tỉnh vùng núi phía Bắc và Duyên hải miền Trung nằm trọn trong cụm có lượng mưa cao và độ ẩm lớn, trong khi nhóm các tỉnh Nam Bộ nằm ổn định ở phân lớp có độ ẩm đồng đều và lượng mưa trung bình. Sự hỗ trợ lẫn nhau giữa mô hình dự báo ngắn hạn và mô hình phân nhóm dài hạn đã cung cấp một hệ công cụ hoàn chỉnh, phục vụ đắc lực cho công tác phân tích và giảm thiểu tác động của biến đổi khí hậu tự nhiên.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

- Sau một thời gian tập trung nghiên cứu, triển khai thực nghiệm và đánh giá hệ thống, đề tài "Phân tích thống kê và ứng dụng Học máy trong dự báo khí hậu tại Việt Nam" đã hoàn thành toàn bộ các mục tiêu đặt ra, đạt được các kết quả cụ thể cả về mặt lý thuyết lẫn ứng dụng thực tiễn.
- Về mặt nghiên cứu và tiền xử lý dữ liệu: Đề tài đã xây dựng thành công một quy trình tiền xử lý và kỹ nghệ đặc trưng chuẩn hóa đối với kho dữ liệu chuỗi thời gian khí tượng quy mô lớn gồm hơn 181,960 bản ghi từ tập dữ liệu thực tế. Các kỹ thuật như bóc tách thành phần thời gian (Temporal Features), mã hóa một-nóng (One-Hot Encoding) giảm thiểu đa cộng tuyến, và chuẩn hóa thang đo Z-score đã biến đổi hiệu quả tập dữ liệu thô thành cấu trúc ma trận số học tối ưu. Giai đoạn này đảm bảo tính công bằng về mặt trọng số giữa các biến độc lập, tạo nền tảng vững chắc cho các tầng thuật toán phía sau hoạt động ổn định.
- Về mặt phân tích thống kê (EDA): Quá trình khai phá dữ liệu đã bóc tách và trả lời trọn vẹn các câu hỏi thực tế về bức tranh khí hậu Việt Nam. Hệ thống đã định danh chính xác các vùng tiêu điểm nhiệt độ cao tại miền Nam, trung tâm mưa lớn kỷ lục (Hoa Bình) tại miền Bắc, cũng như làm rõ quy luật mùa mưa tập trung cực đoan qua các tháng trong năm. Thuật toán phân tích chuỗi ngày mưa liên tục cũng cung cấp một công cụ trực quan mạnh mẽ, giúp định lượng độ kéo dài của thiên tai dồn dập tại các địa phương.
- Về mặt xây dựng mô hình Học máy: Đề tài đã hiện thực hóa thành công cả hai nhánh cấu trúc của Học máy
- Học máy giám sát (XGBoost Regressor): Đã dự báo hiệu quả xu hướng lượng mưa trong vòng 30 ngày tiếp theo tại vùng trọng điểm. Mô hình cây quyết định nâng cao thể hiện năng lực học vệt các biến trễ xuất sắc, bắt kịp các dao động phi tuyến tính cường độ cao mà không rơi vào hiện tượng quá khớp.
- Học máy không giám sát (K-Means Clustering): Đã phân cụm thành công các địa phương dựa trên đặc trưng tương quan giữa lượng mưa và độ ẩm. Biểu đồ phân tán kết quả đã chỉ ra sự phân hóa vĩ mô sâu sắc, thiết lập một bản đồ số khoa học phân vùng khí hậu trực quan.

- Tuy nhiên, đồ án vẫn tồn tại một số hạn chế nhất định do đặc thù phân phối của dữ liệu thời tiết. Lượng mưa là một thuộc tính có độ nhiễu cực lớn, chịu ảnh hưởng bởi các yếu tố bất định toàn cầu như El Niño và La Niña, dẫn đến việc dự báo các mốc mưa cực đoan đột ngột đôi khi còn có độ lệch pha so với thực tế. Bên cạnh đó, việc phân cụm K-Means dù phân tách tốt các nhóm lớn nhưng có thể chưa phản ánh hết các vi khí hậu chuyển tiếp đặc thù tại một số vùng giáp ranh.

5.2. Hướng phát triển

- Từ những kết quả và hạn chế đã ghi nhận, nhóm nghiên cứu đề xuất các phương hướng phát triển mở rộng trong tương lai nhằm tối ưu hóa năng lực ứng dụng thực tế của đề tài:

- + Mở rộng và làm giàu nguồn dữ liệu: Tích hợp thêm các thuộc tính khí tượng tầng cao và các chỉ số viễn thám như bức xạ mặt trời, chỉ số thực vật NDVI, áp suất mực nước biển theo giờ, và các chỉ số chu kỳ khí hậu toàn cầu để gia tăng chiều sâu ngữ cảnh đầu vào cho mô hình hồi quy.
- + Nâng cấp kiến trúc mô hình dự báo: Thử nghiệm và đưa vào ứng dụng các mô hình học sâu chuyên biệt cho chuỗi thời gian dài hạn như Mạng trí nhớ dài ngắn hạn (LSTM - Long Short-Term Memory) hoặc kiến trúc Transformer để cải thiện độ chính xác khi dự báo xa hơn (từ 3 tháng đến 6 tháng tới), giảm thiểu sai số đối với các kịch bản thời tiết cực đoan.
- + Phát triển thuật toán phân cụm động: Ứng dụng các thuật toán phân cụm nâng cao dựa trên mật độ (như DBSCAN) hoặc phân cụm phân cấp (Hierarchical Clustering) để bóc tách sâu hơn các phân lớp khí hậu nhỏ, tự động phát hiện các tỉnh thành có dấu hiệu thay đổi đặc trưng thời tiết nhanh do tác động của biến đổi khí hậu toàn cầu.
- + Xây dựng ứng dụng và tích hợp Chatbot AI: Đóng gói toàn bộ quy trình xử lý và mô hình Học máy thành một hệ thống Web API hoàn chỉnh. Tích hợp giao diện Dashboard tương tác theo thời gian thực kết hợp trợ lý Chatbot thông minh, cho phép người dùng tự động truy vấn chỉ số, nhận cảnh báo sớm thiên tai bão lũ và xem báo cáo dự báo thời tiết trực quan một cách dễ dàng.

TÀI LIỆU THAM KHẢO

I. Tài liệu tiếng Việt

Nguyễn Hải Trung (2022). *Giáo trình Khai phá dữ liệu và Ứng dụng*. Nhà xuất bản Bách Khoa Hà Nội.

Nguyễn Thanh Thủy (2021). *Trí tuệ nhân tạo: Các mô hình học máy cơ bản và nâng cao*. Nhà xuất bản Giáo dục Việt Nam.

Tổng cục Khí tượng Thủy văn (2024). *Báo cáo tổng kết đặc điểm khí hậu Việt Nam và xu hướng biến đổi chuỗi số liệu lịch sử*. Bộ Tài nguyên và Môi trường.

II. Tài liệu tiếng Anh (English References)

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>

McKinney, W. (2022). *Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter* (3rd ed.). O'Reilly Media.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12(Oct), 2825-2830.

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1(14), 281-297.

III. Nguồn dữ liệu trực tuyến và Tài liệu lập trình (Online Sources & Documentation)

Meteostat Developers. (2026). *Meteostat Python Library Documentation (Open Meteorological Data)*. Truy cập ngày 21 tháng 06, 2026, từ <https://dev.meteostat.net/python/>

Pandas Development Team. (2025). *Pandas: Powerful data structures for data analysis, time series, and statistics*. Truy cập từ <https://pandas.pydata.org/docs/>

XGBoost Documentation. (2025). *XGBoost Parameters and Gradient Boosting Framework Guide*. Truy cập từ <https://xgboost.readthedocs.io/>

